

LAPORAN DATA DAN PERSIAPAN DATASET PELANGGAN

Ringkasan diskusi tentang data e-commerce dan prediksi churn

Ringkasan

Laporan ini menjelaskan empat file CSV sumber, alur kerja pada `data_prep.py`, serta isi dan struktur tiga dataset hasil. Data digunakan untuk latihan machine learning yang memprediksi churn pelanggan. Satu baris pada tabel pelanggan mewakili satu pelanggan; satu baris pada tabel pesanan mewakili satu pesanan.

Data sumber: 8.000 pelanggan, 25.000 pesanan, 140 baris ringkasan produk, dan 75 baris ringkasan bulanan. Dataset dibagi menjadi 6.400 baris train dan 1.600 baris test.

1. File data sumber

customers.csv

Satu baris per pelanggan. Kolom mencakup ID, negara, usia, gender, tier keanggotaan, tanggal registrasi, jumlah pesanan, total dan rata-rata belanja, waktu sejak pembelian terakhir, preferensi belanja, ulasan, retur, wishlist, langganan newsletter, dan target churned (0 atau 1). Contoh: C00001 berasal dari United States, berusia 40 tahun, memiliki 4 pesanan, dan churned = 0.

orders.csv

Satu baris per pesanan. Kolom mencakup ID pesanan dan pelanggan, tanggal dan periode, produk/kategori, harga dan kuantitas, subtotal, diskon, ongkos kirim, pajak, total pembayaran, metode pembayaran, perangkat, lama pengiriman, status, retur, rating, aktivitas sesi, dan penanda pelanggan berulang.

product_summary.csv

Ringkasan per produk dan kategori: jumlah pesanan, total pendapatan, harga dan rating rata-rata, tingkat retur, diskon rata-rata, serta rata-rata lama pengiriman.

monthly_revenue.csv

Ringkasan per bulan dan tahun: kuartal, jumlah pesanan, pendapatan, nilai pesanan rata-rata, diskon rata-rata, tingkat retur, jumlah pelanggan unik, dan pelanggan baru. File merangkum pesanan terkirim; `return_rate` bernilai nol. Gunakan `orders.csv` untuk analisis retur.

2. Proses pada `data_prep.py`

Script membaca empat CSV dan memvalidasi kolom wajib. Tanggal diubah ke format tanggal, lalu tanggal snapshot ditetapkan dari tanggal terbaru di sumber data. Script membuat `customer_tenure_days` (lama menjadi pelanggan), `orders_per_year`, `reviews_per_order`, dan `returns_per_order`.

Target churned dikonversi menjadi integer. Kategori tetap berupa teks; encoding dilakukan di pipeline scikit-learn pada `ml_model.py`. Pembagian data memakai rasio 80/20, `random_state=42`, dan stratifikasi berdasarkan target agar proporsi churn terjaga.

3. Struktur dataset hasil

Semua file hasil memiliki kolom yang sama. ID: `customer_id`. Kategori (7): `country`, `gender`, `membership_tier`, `preferred_category`, `preferred_device`, `preferred_payment_method`, `acquisition_channel`.

Numerik sumber (10): `age`, `total_orders`, `total_spend_usd`, `avg_order_value_usd`, `days_since_last_purchase`, `reviews_given`, `avg_review_score`, `returns_made`, `wishlist_items`, `newsletter_subscribed`.

Fitur turunan (4): `customer_tenure_days`, `orders_per_year`, `reviews_per_order`, `returns_per_order`. Target: `churned`. Total 21 fitur model sebelum one-hot encoding (7

kategori + 14 numerik). `customer_id` disertakan untuk menelusuri baris, bukan sebagai fitur model.

customer_ml_dataset.csv

Dataset lengkap setelah fitur turunan ditambahkan: 8.000 baris pelanggan.

customer_train.csv

Bagian untuk melatih model: 6.400 baris (80%).

customer_test.csv

Bagian untuk mengevaluasi model: 1.600 baris (20%).

4. Catatan kualitas data

Tingkat churn pelanggan 8,94%; tingkat retur pesanan 8,08%; rating kosong pada 63% pesanan.

Sebanyak 20.497 pesanan berstatus terkirim dengan pendapatan USD 2.585.126,50. Total pendapatan ringkasan produk cocok dengan pesanan non-batal, dan total pendapatan bulanan cocok dengan pesanan terkirim.

Tanggal snapshot pada laporan kualitas data: 1 April 2026. Angka merujuk pada file yang ada di folder simulation saat laporan disusun.

Kesimpulan

Empat CSV sumber menyajikan data pelanggan, pesanan, produk, dan ringkasan bulanan.

`data_prep.py` memvalidasi sumber, menambah empat fitur turunan, lalu menyimpan dataset lengkap dan pembagian train/test untuk latihan klasifikasi churn.